

Telco Customer Churn

Predictive Analysis Report

Un progetto di machine learning per identificare i clienti a rischio di abbandono.

7,032	26.6%	18	0.841	81,8%
Clienti analizzati	Tasso di churn complessivo	Feature utilizzate	Best ROC-AUC	Curners identificati

Marzo 2026 | Progetto di Machine Learning

1. Obiettivo del Progetto

Ogni anno, le aziende di telecomunicazioni perdono una parte significativa dei loro clienti a favore dei concorrenti, è un fenomeno chiamato churn. Quando un cliente se ne va, l'azienda non solo perde il suo ricavo mensile, ma deve anche spendere 5–7 volte di più per trovare un nuovo cliente che lo sostituisca. Con un tasso di churn del 26,6%, circa 1 cliente su 4 abbandona il servizio.

L'obiettivo di questo progetto è identificare i clienti che probabilmente se ne andranno prima che lo facciano davvero. Segnalando in anticipo i clienti a rischio, il team di retention ottiene una lista prioritaria di persone da contattare con offerte speciali o supporto, mantenendo i ricavi e riducendo il costo della perdita di clienti.

Metrica	Valore
Dimensione del dataset	7,032 customers
Tasso di churn	26,6% (~1 su 4 abbandona)
Churner stimati nel dataset	~1,869 customers
Rapporto costi: acquisire vs trattenere	5–7x più costoso acquisire un nuovo cliente
Recall del modello sui churner	81,8%

2. Panoramica dei Dati

Il dataset proviene da un'azienda di telecomunicazioni e comprende 7.032 clienti (dopo aver rimosso 11 righe con tenure pari a zero e dati mancanti). Ogni cliente ha 20 feature suddivise in tre gruppi:

Dati demografici: genere, status di anziano, partner, persone a carico

Dati account: tenure (mesi), tipo contratto, metodo di fatturazione, metodo di pagamento*

Servizi sottoscritti: telefono, internet (DSL / Fibra ottica), sicurezza online, backup, streaming, ecc.

* MonthlyCharges e TotalCharges sono stati rimossi a causa dell'elevata multicollinearità ($VIF > 10$) con le feature dei servizi e la tenure.

Squilibrio di classe: il 73,4% dei clienti è rimasto (No Churn) contro il 26,6% che ha abbandonato (Churn). Questo squilibrio è stato gestito in fase di modellazione.




Figura 1. Distribuzione delle tre feature numeriche (tenure, monthly charges, total charges) suddivise per stato di churn. I clienti che abbandonano tendono ad avere una tenure più bassa e un canone mensile più alto.

Feature: Tenure

- L'istogramma per i clienti che abbandonano (rosso) raggiunge il picco nei primi 0–5 mesi. Il boxplot lo conferma, mostrando una tenure mediana bassa di circa 10 mesi per chi se ne va. Al contrario, il gruppo che rimane (blu) mostra un picco verso destra, intorno ai 70 mesi.
- Osservazione: I nuovi clienti sono a maggior rischio di abbandono. Tuttavia, se un cliente supera i primi mesi critici, è molto probabile che diventi un abbonato fedele a lungo termine.

Feature: Monthly Charges

- I boxplot mostrano un chiaro divario nei pagamenti tipici tra i due gruppi. Il canone mensile mediano per i clienti che abbandonano è significativamente più alto (~80) rispetto a quelli che rimangono (~65).
- Osservazione: Le bollette mensili più alte sono fortemente correlate con un rischio di churn più elevato. I clienti con piani più costosi stanno abbandonando a un ritmo molto più alto.




Figura 2. Conteggio del churn per tutte le feature categoriche. I contratti mensili e la fibra ottica mostrano i volumi di churn più alti.

Profili ad Alto Rischio (Predittori Principali):

- **Contratto:** I clienti con contratti mensili abbandonano a tassi molto elevati. Una volta che un cliente firma un contratto annuale o biennale, il rischio di churn scende significativamente.
- **InternetService:** I clienti che utilizzano la Fibra ottica stanno abbandonando in una proporzione significativamente più alta rispetto a quelli con DSL o senza servizio internet. Questo potrebbe indicare un problema di prezzo, affidabilità o concorrenza del servizio in fibra.
- **PaymentMethod:** I clienti che pagano tramite electronic check hanno un tasso di churn visibilmente più alto rispetto ai bonifici automatici o alle carte di credito.
- **Servizi Aggiuntivi:** OnlineSecurity, TechSupport, OnlineBackup e DeviceProtection seguono lo stesso schema. I clienti che hanno internet ma non sottoscrivono questi servizi aggiuntivi abbandonano a un tasso molto alto. I clienti che li sottoscrivono hanno meno probabilità di andarsene.
- **Dati demografici:** I clienti senza persone a carico o partner hanno tassi di churn più alti rispetto a quelli con famiglie. Inoltre, sebbene ci siano meno SeniorCitizens in totale, la proporzione di SeniorCitizens che abbandona è notevolmente più alta rispetto ai non-senior.




Figura 3. Matrice di correlazione delle feature numeriche.

La matrice di correlazione conferma che una tenure più lunga riduce il rischio di churn (-0,35), mentre canoni mensili più alti lo aumentano (0,19).

La matrice di correlazione ha rivelato che TotalCharges è fortemente correlata sia con tenure (0,83) che con MonthlyCharges (0,65). TotalCharges è essenzialmente $\text{tenure} \times \text{MonthlyCharges}$, quindi non porta informazioni indipendenti. Allo stesso modo, MonthlyCharges riflette direttamente i servizi a cui un cliente è abbonato, il che significa che era già catturata dalle singole variabili di servizio.

Entrambe le variabili sono state rimosse prima della modellazione. L'analisi VIF sulle variabili rimanenti ha confermato la correttezza della decisione. Tutti i valori sono risultati inferiori a 10, indicando l'assenza di multicollinearità significativa.

3. Principali Fattori di Rischio (Regressione Logistica)

Il modello di regressione logistica fornisce coefficienti interpretabili che ci dicono esattamente quanto ogni feature aumenta o diminuisce la probabilità di churn. Di seguito sono riportati i sei principali insight di business da questi risultati (i log-odds sono stati convertiti in odds ratio per una maggiore interpretabilità).

1. Tipo di Contratto

RISCHIO
ALTO

Risultato: I clienti con contratto biennale hanno il 75% di odds in meno di abbandonare ($OR = 0,25$) rispetto ai clienti mensili. Questo è il fattore protettivo più forte del modello. I clienti mensili (month-to-month) non hanno costi di switching e abbandonano a tassi molto più alti.

Azione Raccomandata: Offrire sconti o blocchi di prezzo per convertire i clienti mensili a contratti annuali o biennali, soprattutto entro i primi 6 mesi.

2. Clienti Fibra Ottica: il Maggior Rischio di Churn

RISCHIO
ALTO

Risultato: I clienti con fibra ottica hanno odds di abbandono 146% più alte ($OR = 2,47$) rispetto ai clienti DSL. Nonostante sia un prodotto premium, questi clienti appaiono insoddisfatti, probabilmente per il prezzo o la qualità del servizio.

Azione Raccomandata: Condurre sondaggi di soddisfazione post-installazione. Verificare se prezzi, velocità o affidabilità non soddisfano le aspettative. Valutare un benchmark con i concorrenti nel segmento fibra.

3. Il Primo Anno è la Zona di Rischio

RISCHIO
ALTO

Risultato: La tenure è uno dei fattori protettivi più forti del modello. Più a lungo un cliente rimane, meno è probabile che se ne vada. I nuovi clienti abbandonano a un tasso molto più alto.

Azione Raccomandata: Investire in programmi di onboarding: chiamate di benvenuto, check-in a 30/60/90 giorni e premi fedeltà al raggiungimento dei 12 mesi.

4. Gli Utenti con Assegno Elettronico Abbandonano di Più

RISCHIO
MEDIO

Risultato: I clienti che pagano tramite assegno elettronico hanno il 48% di odds in più di abbandonare ($OR = 1,48$) rispetto a quelli con pagamento automatico. I pagatori manuali sono meno "legati" al servizio.

Azione Raccomandata: Offrire un piccolo sconto mensile o dati bonus ai clienti che passano al pagamento automatico tramite carta di credito o bonifico bancario.

5. I Clienti Senza Persone a Carico Sono a Maggior Rischio

RISCHIO
MEDIO

Risultato: I clienti senza persone a carico hanno il 28% di odds in più di abbandonare (OR = 1,28) rispetto a quelli con persone a carico. I clienti singoli hanno costi di switching più bassi (e.g. nessun piano familiare da trasferire).

Azione Raccomandata: Rivolgere promozioni di bundle familiare ai clienti con linea singola e senza persone a carico per aumentare il loro costo percepito di switching.

6. Gli Anziani Necessitano di Attenzione Extra

RISCHIO
MEDIO

Risultato: Gli anziani hanno il 21% di odds in più di abbandonare (OR = 1,21) rispetto ai non anziani. Questo è sorprendente poiché questo gruppo tipicamente valuta la stabilità.

Azione Raccomandata: Considerare una linea di supporto dedicata o un piano semplificato per anziani per ridurre le difficoltà e migliorare la soddisfazione di questo segmento.

4. Performance dei Modelli

Tre modelli sono stati costruiti e confrontati. La Recall è stata scelta come metrica principale perché perdere un churner (falso negativo nella Matrice di Confusione) è più costoso che segnalare erroneamente un cliente fedele (falso positivo). Se segnaliamo erroneamente un cliente fedele, gli inviamo solo un'offerta inutile. Se perdiamo un churner, lo perdiamo del tutto.

4.1 Confronto tra Modelli

Modello	Accuracy	F1-Score	Recall	ROC-AUC
Logistic Regression	80,3%	73,9%	73,2%	0.833
Random Forest	77,4%	53,9%	49,7%	0.810
XGBoost	72,7%	60,3%	77,8%	0.832



Figura 4. Grafico a barre che confronta le quattro metriche sui tre modelli nel test set.

L'Accuracy non è la metrica principale perché lo squilibrio di classe (73/27) significa che un modello banale che predice sempre 'nessun churn' raggiungerebbe il 73% di accuratezza senza identificare nessun churner. La Recall sulla classe minoritaria è la metrica che riflette il vero costo per il business.

Il Random Forest fallisce sulla nostra metrica principale, la Recall: predice "No Churn" per quasi tutti, perdendo più della metà dei clienti che stanno per andarsene.

Sebbene la Regressione Logistica identifichi meno churner rispetto a XGBoost, ha un F1 Score significativamente più alto.

XGBoost vince chiaramente sulla nostra metrica principale, la Recall. È anche al primo posto sul ROC-AUC, il che significa che è eccellente nel separare i clienti ad alto rischio da quelli sicuri.

XGBoost identifica più churner, ma genera anche più falsi allarmi (segnalando clienti fedeli come churner). La Regressione Logistica è un po' più conservativa e precisa.

4.2 Curve ROC

La curva ROC mostra quanto bene ogni modello separa i churner dai non-churner su tutte le possibili soglie di decisione. Un AUC più alto significa migliori prestazioni complessive. Tutti tre i modelli superano ampiamente 0,8, un risultato solido per questo tipo di problema.




Figura 5. Curve ROC per tutti e tre i modelli. XGBoost e Regressione Logistica sono quasi identici, entrambi superiori al Random Forest.

4.3 Stabilità della Cross-Validation

Per verificare che i risultati siano affidabili e non solo fortunati su una particolare suddivisione del test, è stata eseguita una cross-validation stratificata a 5 fold sui dati di training. I risultati confermano che XGBoost è il modello più coerente. XGBoost (0.8444 ± 0.0061) supera il Random Forest (0.8216 ± 0.0079) e mostra meno varianza, inoltre, il Random Forest presenta un outlier, il che significa che XGBoost è più stabile.




Figura 6. ROC-AUC della cross-validation su 5 fold.

4.4 Modello Finale

XGBoost è il nostro modello vincitore. Pur sacrificando un po' di accuratezza complessiva rispetto alla Regressione Logistica, XGBoost raggiunge la Recall più alta (81,8%) e mantiene un ROC-AUC molto competitivo (0,841), significativo per l'obiettivo fissato. Scegliendo XGBoost, il team di retention dispone di uno strumento più efficace per identificare i ricavi a rischio.

La matrice di confusione mostra le previsioni del modello finale su 1.407 clienti del test set. Su 374 churner reali, il modello ne ha identificati correttamente 306 (Recall 81,8%). Ha anche mantenuto in gran parte intatti i clienti fedeli, con 720 classificati correttamente come rimasti.




Figura 7. Matrice di confusione XGBoost ottimizzato sul test set. 306 churner reali identificati su 374 totali.

5. Cosa Determina il Churn. Importanza delle Feature e SHAP

Sono stati utilizzati due metodi complementari per capire su quali feature il modello XGBoost si basa maggiormente.

5.1 Importanza delle Feature (MDI)

Il grafico mostra quanto ogni feature riduce l'errore di previsione su tutti gli trees. Le feature più importanti corrispondono strettamente agli insight di business della regressione logistica, il che aumenta la nostra fiducia in questi risultati.




Figura 8. Le 15 feature più importanti per XGBoost

5.2 Valori SHAP

SHAP mostra non solo quali feature contano, ma anche in quale direzione spingono ogni previsione. Ogni punto è un cliente. Rosso = valore alto della feature, blu = valore basso. Punti a destra = spinti verso il churn, punti a sinistra = spinti lontano dal churn.




Figura 9. SHAP summary plot per il modello XGBoost.

- Le feature dei contratti biennali e annuali si trovano in cima al grafico SHAP. I punti rossi (clienti con questi contratti) spingono fortemente a sinistra, il che significa che i contratti a lungo termine riducono drasticamente il rischio di churn. I clienti mensili senza contratto sono il gruppo più vulnerabile dell'intero dataset.
- La fibra ottica è la terza feature più importante, ma funziona nella direzione sbagliata. I punti rossi (clienti con fibra ottica) spingono fortemente a destra, il che significa che avere internet in fibra ottica aumenta la probabilità di abbandonare. Questo è un problema di prodotto o di prezzo che richiede un'indagine urgente.
- Per la tenure, i punti blu (nuovi clienti con tenure bassa) si estendono lontano a destra. I primi 6–12 mesi sono la finestra di rischio più alta. I clienti che superano quel punto diventano più fedeli e stabili.
- Feature come OnlineSecurity, TechSupport e OnlineBackup mostrano tutte lo stesso schema: i punti rossi (clienti che hanno questi servizi) spingono a sinistra. I clienti con servizi aggiuntivi hanno meno probabilità di abbandonare.

Il grafico SHAP conferma che il modello XGBoost ha appreso gli stessi pattern della regressione logistica. Due approcci di modellazione completamente diversi (lineare e tree-based) indicano gli stessi fattori di rischio. Il grafico SHAP lo rende visibile.

6. Ottimizzazione degli Iperparametri

Per trovare le migliori impostazioni possibili per XGBoost, è stata utilizzata l'Ottimizzazione Bayesiana (tramite la libreria Optuna) per cercare automaticamente le migliori impostazioni. Invece di provare tutte le combinazioni manualmente, Optuna esegue 50 trial, imparando dai risultati precedenti per concentrarsi sulle aree più promettenti dello spazio di ricerca. La Grid Search avrebbe richiesto di testare migliaia di combinazioni manualmente; Optuna trova invece una buona soluzione in soli 50 trial. Per questo motivo è stata scelta.

Parametro	Intervallo di Ricerca	Miglior Valore Trovato
n_estimators (trees)	100 – 500	400
max_depth (tree depth)	3 – 8	3
learning_rate	0.01 – 0.30	0.0153
subsample	0.50 – 1.00	0.571
colsample_bytree	0.50 – 1.00	0.985
reg_alpha (L1)	0.0001 – 10	0.044
reg_lambda (L2)	0.0001 – 10	0.00038

Miglior ROC-AUC della cross-validazione raggiunto dopo l'ottimizzazione: 0,851 (rispetto a 0,832 del baseline). Gli alberi poco profondi (max_depth = 3) e il basso learning rate suggeriscono che il modello beneficia di molti aggiornamenti piccoli e conservativi piuttosto che di pochi alberi profondi.

- max_depth = 3 significa che il modello pone solo 3 domande sì/no prima di prendere una decisione. Non cerca di memorizzare pattern complessi.
- Un basso learning rate (0,012) significa che ogni albero contribuisce solo con una piccola correzione a quello precedente. Il modello compie molti piccoli passi prudenti invece di pochi passi grandi.

Il modello ottimizzato usa 400 alberi poco profondi con un basso learning rate, il che significa che apprende in modo graduale e attento, aiutandolo a performare bene su clienti mai visti prima.

Modello	Accuracy	F1-Score	Recall	ROC-AUC
Logistic Regression	80,3%	73,9%	73,2%	0.833
Random Forest	77,4%	53,9%	49,7%	0.810
XGBoost (baseline)	72,7%	60,3%	77,8%	0.832
XGBoost (tuned) ✓	73,0%	61,6%	81,8%	0.841

✓ Modello finale selezionato. L'XGBoost ottimizzato raggiunge la Recall più alta (81,8%) e il miglior ROC-AUC (0,841), il che significa che identifica il maggior numero di churner.

7. Azioni Consigliate

Sulla base dei risultati del modello, si raccomandano le seguenti azioni, ordinate per impatto stimato sul business:

- 1 Convertire i clienti mensili a contratti a lungo termine**
ROI più alto. Rivolgersi ai clienti nei mesi 1–6 con un’offerta di sconto per passare a piani annuali o biennali. Il tipo di contratto è il singolo fattore protettivo più forte.
- 2 Migliorare l’esperienza della fibra ottica**
I clienti con fibra ottica sono pagatori premium ma anche il gruppo a più alto rischio di churn. Condurre sondaggi di soddisfazione, fare benchmark con i concorrenti e considerare una garanzia di qualità del servizio o un programma di pareggio prezzi.
- 3 Investire nell’onboarding dei nuovi clienti (mesi 0–12)**
Il primo anno è critico. Implementare un percorso di onboarding strutturato: chiamata di benvenuto, check-in a 30/60/90 giorni e un premio fedeltà al raggiungimento dei 12 mesi.
- 4 Incentivare l’adozione del pagamento automatico**
Gli utenti con assegno elettronico abbandonano di più. Un piccolo credito mensile in bolletta per passare al pagamento automatico ha un costo basso e rende i clienti più fedeli.
- 5 Rivolgere bundle familiari ai clienti con linea singola**
I clienti senza persone a carico e senza partner hanno costi di switching più bassi. I bundle familiari e i programmi di referral aumentano il valore percepito del rimanere.
- 6 Creare un programma di supporto per gli anziani**
Una linea di assistenza dedicata o un piano semplificato per i clienti anziani potrebbe ridurre le difficoltà e migliorare la loro soddisfazione, affrontando il loro tasso di churn insolitamente alto.

8. ROI Atteso

Per illustrare il valore finanziario del modello, si consideri la seguente stima conservativa basata sulle prestazioni del test set e sulla tipica economia delle telecomunicazioni:

Ipotesi / Metrica	Valore
Dimensione del test set	1.407 clienti
Churner reali nel test set	374 clienti
Recall del modello (churner identificati correttamente)	81.8% → 306 customers
Ricavo mensile medio stimato per cliente	\$65
Durata media stimata del cliente (mesi)	24
Ricavo a rischio per churner	$\$65 \times 24 = \$1,560$
Ricavo totale a rischio (374 churner)	$374 \times \$1,560 = \$583,440$
Ricavo recuperabile se il 30% dei churner identificati viene trattenuto	$306 \times 30\% \times \$1,560 = \sim \$143,208$
Costo della campagna di retention (stima \$20/cliente)	$306 \times \$20 = \$6,120$
Risparmio netto (test set)	\$137,088

Nota: Stime illustrative.

9. Conclusione

Questo progetto ha costruito un modello di previsione del churn dei clienti che identifica l'81,8% dei clienti a rischio prima che se ne vadano, con un ROC-AUC di 0,841. Il modello ha seguito un pipeline rigoroso: analisi esplorativa dei dati, ingegnerizzazione delle feature, regressione logistica, modelli ensemble (Random Forest e XGBoost) e ottimizzazione bayesiana degli iperparametri con Optuna.

L'analisi ha identificato sei azioni di business. Insieme, rappresentano una strategia di retention strutturata e basata sui dati su cui il business può agire immediatamente.

Il segmento a più alto rischio e il target più azionabile per le campagne di retention è costituito dai nuovi clienti (tenure < 12 mesi) con contratti mensili e internet in fibra ottica. È qui che una campagna di retention avrà il massimo impatto.

Modello	ROC-AUC	Recall	Stato
Regressione Logistica (statsmodels)	0.833	73,2%	Baseline
Random Forest	0.810	49,7%	Scartato
XGBoost (default)	0.832	77,8%	Migliorato
XGBoost (ottimizzato con Optuna)	0.841	81,8%	MODELLO FINALE